

# 설명 가능한 KBO 승패 예측 모델

---

SPOTV 산학협력 1팀

민세희, 배순은, 이주원, 장준한

# 프로젝트 진행 배경

---

사측 요구사항



설명 가능한 예측 모델

단순 예측을 넘어 "왜 이겼는가"를 해석할 수 있는 지표



경기 전/중/후 구조화

시점별로 연결되는 일관된 스토리라인



실사용 관점

실제 야구 시청자가 원하는 정보를 출발점으로



콘텐츠 연계

예측 결과를 쇼츠·인포그래픽 형태로 제공 가능한 구조



최종 프로젝트 목표

경기 전/중/후 시점별로 구조화된 스토리라인

경기 전

설명 가능한 승패 예측 모델

경기 중

실시간 승리확률 변동 감지

경기 후

승패 요인 분석 및 What-if 시나리오

## BEFORE



- 스포타임 베이스볼
  - 해설위원의 승부예측 + 예상 득점 제공
- 선발투수 + 상대전적 기반 승부예측



## 설명 가능한 승패 예측 모델

### 모델

- 경기 승패 예측 확률 모델 개발
- 예측 결과에 영향을 미친 주요 변수 설명이 가능한 Explainable AI 기반 모델 설계
- 선발투수, 타선 컨디션, 불펜 등 경기 전 정보를 활용한 예측 모델 구축


### 산출물

- AI 코멘터리 자동 생성 (예측 근거 설명)
- 인스타그램 스토리 카드

# 파이프라인 소개

---

## 전체 파이프라인




### 사측 제공 데이터

- KBO 경기의 Pitch/Event 단위 로그 데이터

### 프로젝트 목표

- 경기 전 홈팀 승리 확률  $P(\text{home win})$  예측
- 향후 지속 활용 가능한 모델 제작
- 설명력 있는 모델 구축

## Raw Data EDA & Target 생성



The image shows a large, dense table representing raw data. The table has many columns and rows, with a red arrow pointing from a specific row to a text box below.

- 기간: 2025시즌 전체 + 2026시즌 3~6월
- 단위: pitch/event-level log
- 규모: 340,197행 × 136컬럼
- 경기 수: 999경기
- 팀 수: 10개 구단
- 예측 타깃: 홈 승리
- 홈승: 1
- 원정승: 0
- 무승부, 광주 구장: 제외
- 최종 데이터: 973경기
- 홈승: 502회
- 원정승: 471회

각 행은 경기 중 발생한  
하나의 투구 또는 경기 이벤트를 나타냄

Pitch Event Log에서 경기별 출전 선수와 좌우 매치업에 필요한 기본 정보를 추출

선발투수



- 목적: 경기 전 예측에 필요한 선발투수 정보 확보
- 기준
  - 선발투수 포지션에 해당하는 선수
  - 경기 x 팀별 첫 번째 투구자
- 좌/우투수 여부 정보 추출

선발타순

| NC다이노스       |    |       |      | 두산 베어스 ( 2 차전) |    |       |      |
|--------------|----|-------|------|----------------|----|-------|------|
| 선발투수 : 테 윌 러 |    |       |      | 선발투수 : 박 비     |    |       |      |
| 타순           | 위치 | 선 수 명 | 교체선수 | 타순             | 위치 | 선 수 명 | 교체선수 |
| 1            | SS | 김 주 원 |      | 1              | SS | 박 찬 호 |      |
| 2            | LF | 권 희 동 |      | 2              | CF | 정 수 빈 |      |
| 3            | 2B | 박 민 우 |      | 3              | 1B | 김 승 호 |      |
| 4            | 1B | 테 이 비 |      | 4              | C  | 양 의 지 |      |
| 5            | DH | 박 건 우 |      | 5              | 2B | 박 준 순 |      |
| 6            | 3B | 김 휘 집 |      | 6              | 3B | 안 재 석 |      |
| 7            | C  | 김 형 주 |      | 7              | 1B | 양 석 환 |      |
| 8            | RF | 천 재 환 |      | 8              | LF | 김 민 석 |      |
| 9            | CF | 최 정 원 |      | 9              | RF | 박 지 훈 |      |

- 목적: 경기별 실제 선발 라인업 9명 확보
- 기준
  - 경기 x 팀 x 타순별 가장 먼저 등장한 타자
- 좌/우타자 여부 정보 추출

선수 단위 기록을 경기 맥락에 맞는 Team 단위 Feature로 변환

타자 Feature

- 상대 선발투수가 **우투수**인 경우: **우투수 상대 성적** 사용
- 상대 선발투수가 **좌투수**인 경우: **좌투수 상대 성적** 사용

상대 선발투수의 투구 유형(좌/우)



**타자 Feature Split 선택**  
우투수 상대 성적 / 좌투수 상대 성적

투수 Feature

- 상대 라인업의 좌타/우타 구성 **비율**을 계산
- 투수의 좌타 상대 성적과 우타 상대 성적을 **비율에 따라 가중합**

상대 선발라인업의 좌/우타자 구성 비율



**투수 Feature Split 가중합**  
(우타 상대 성적 × 우타 비중) + (좌타 상대 성적 × 좌타 비중)

이후 팀 단위로 집계한 뒤 홈팀과 원정팀의 차이값 생성

## 홈팀 - 원정팀 차이값을 활용한 Feature 설계

**핵심 구조**  $\text{diff\_} = (\text{홈팀 값} - \text{원정팀 값})$

→ 절대값이 아닌 상대적 우열을 학습

### 타자 Feature

선발 라인업 9명 집계

- ▶ K%, wOBA
- ▶ OPS · 하드히트 비율 · 타구 비거리 · 타율 등 총 21개

### 투수 Feature

선발 + 불펜 가중 혼합


- ▶ Strike%, K-BB%, 피타구 발사각, 강타구 허용률, 땅볼/뜬공 비율
- ▶ 구속 · 회전수 · 수직·수평 무브먼트 · WHIP 등 총 24개

### 집계 방식

- ▶ 윈도우: all\_to\_date (누적·안정)

단순 시즌 평균이 아니라 **해당 경기의 선발 매치업을 반영한 feature**를 구성

## Preprocessing Outputs



### 경기 결과 테이블

- 모델의 정답 라벨
- 최종 점수 및 득실차 기준

### 선발투수 테이블

- Feature 연결 기준
- 상대 타자 Split 선택 기준 제공

### 선발라인업 테이블

- 선발 9명 타자 Feature 집계 기준
- 상대 투수 Split 가중합 기준 제공

### 최종 경기 단위 데이터셋

- 투수/타자 Feature를 경기 단위로 병합
- 홈팀과 원정팀의 상대적 전력 차이를 표현

전처리 파이프라인

- ▶ **Pipeline:** 중앙값 대치 → 표준화 → 모델
- ▶ **누수 차단:** Fold 내 Train으로만 fit (표준화·결측까지)

비교 모델

- ▶ Logistic · RF · XGBoost · LightGBM 총 4가지 모델 비교
- ▶ Feature 조합별 성능을 AUC · Accuracy · 안정성 기준 교차 검증

평가 지표

| 지표               | 핵심 관점           | 방향   |
|------------------|-----------------|------|
| AUC              | 순위 분리력 (임계값 무관) | ↑    |
| Accuracy         | 0.5 임계값 기준 적중률  | ↑    |
| Brier            | 확률값의 정확도        | ↓    |
| LogLoss          | 확신 오류에 대한 페널티   | ↓    |
| auc_std / Sharpe | fold 간 성능 안정성   | 안정 ↑ |

\* 소표본 변동성 통제를 위해 성능과 안정성을 동시 측정

승리 확률 예측 모델 → 정확도뿐 아니라 확률 품질과 안정성까지 평가

# 최종 OUTPUT

---

모델 스펙

- ▶ **RandomForest** (500그루, depth 3, leaf 5, class\_balanced)
- ▶ **입력:** 경기 전날까지 누적 기록 · 973경기
- ▶ Logistic·RF·XGBoost·LightGBM 동일 조건에서 비교해 7개 피처 확정

사용 피처

- ▶ **타자 피처**  
타선 삼진율(K%) · 타선 wOBA
- ▶ **투수 피처**  
투수진 스트라이크% · K-BB% · 피타구 발사각  
강타구 허용률 · 땅볼/뜬공 비율

성능

\* hold-out 기반 성능

| Accuracy | AUC    | Brier  | LogLoss |
|----------|--------|--------|---------|
| 0.6355   | 0.6703 | 0.2350 | 0.6627  |

선정 근거

- ▶ 모델 선정은 CV AUC 기반, hold-out 점수는 선정에 미사용  
→ hold-out 오염 방지
- ▶ 타자+투수를 모두 담은 통합 모델 → 설명 가능성 목표에 부합
- ▶ SHAP(TreeExplainer)으로 예측 확률을 요인별로 분해 가능
- ▶ 973경기도 여전히 소표본 → 데이터 추가 시 결과가 달라질 수 있음

성능 최대화가 아닌 **설명 가능한 통합 모델**을 최종 채택

정답 예시

| 경기일          | 매치업          | 실제 결과 | 모델 예측    | 홈팀 승리확률 |
|--------------|--------------|-------|----------|---------|
| 2026. 6. 11. | 키움 vs NC (홈) | 원정팀 승 | 원정팀 승 예측 | 0.319   |
| 2026. 6. 2.  | 삼성 vs NC (홈) | 홈팀 승  | 홈팀 승 예측  | 0.644   |

오답 예시

| 경기일          | 매치업          | 실제 결과 | 모델 예측    | 홈팀 승리확률 |
|--------------|--------------|-------|----------|---------|
| 2026. 6. 27. | 삼성 vs KT (홈) | 홈팀 승  | 원정팀 승 예측 | 0.34    |
| 2026. 6. 18. | 두산 vs KT (홈) | 홈팀 승  | 원정팀 승 예측 | 0.376   |

▶ SHAP을 활용하여  
예측 요인 분석

6월 hold-out 107경기 전체에 대한 평균 SHAP 중요도

| 변수                 | SHAP 중요도 | 의미              |
|--------------------|----------|-----------------|
| diff_Strike_pct    | 0.0346   | 투수진 스트라이크% 차이   |
| diff_bat_all_K_pct | 0.023    | 타선 삼진율 차이       |
| diff_K_BB_pct      | 0.016    | 투수진 K-BB% 차이    |
| diff_LA_mean       | 0.0137   | 투수진 피타구 발사각 차이  |
| diff_bat_all_wOBA  | 0.0116   | 타선 wOBA 차이      |
| diff_HardHit_pct   | 0.0042   | 투수진 강타구 허용률 차이  |
| diff_GF_ratio      | 0.0028   | 투수진 땅볼/뜬공 비율 차이 |



경기별 SHAP 결과 기반  
LLM 코멘터리 생성

입력

경기별 SHAP → JSON

경기: 2026-06-30 NC(홈) vs 삼성(원정)  
예측 홈승 확률: 54.1%

| 변수          | 승률 기여  |
|-------------|--------|
| 투수진 스트라이크%  | +1.8%p |
| 타선 삼진율(K%)  | +1.4%p |
| 투수진 K-BB%   | -1.3%p |
| 투수진 피타구 발사각 | +1.0%p |
| 투수진 강타구 허용률 | +0.7%p |
| ...         |        |



출력

NC 다이노스가 홈에서 삼성 라이온즈를 상대로 약 54.1%의 승리 가능성을 보이며 근소한 우세가 점쳐지지만, 예측 신뢰도가 낮아 치열한 접전이 예상됩니다. NC 다이노스는 타선 삼진율에서 16.0%를 기록하며 삼성 라이온즈(17.5%)보다 삼진을 덜 당하는 정교함을 갖췄고, 투수진의 강타구 허용률도 30.1%로 삼성 라이온즈(34.3%)보다 낮아 장타를 억제하는 데 우위가 있습니다. 반면 삼성 라이온즈는 투수진의 삼진 대비 볼넷 비율(K-BB%)에서 7.9%로 NC 다이노스(5.1%)보다 앞서며 더 뛰어난 마운드 지배력을 보여줍니다. 양 팀 투수진의 스트라이크 비율(NC 다이노스 62.4%, 삼성 라이온즈 62.8%)과 타선 생산력(wOBA NC 다이노스 0.340, 삼성 라이온즈 0.342)은 팽팽한 백중세를 이루고 있어 당일 집중력이 승부를 가를 것입니다.


## 특징


- Gemini Flash / OpenAI 둘 다 지원
  - .env의 LLM\_PROVIDER로 전환

### 코멘터리 생성 시의 4가지 안정장치

- SHAP 값은 인과관계가 아님
- 승률 기여는 팀 간 차이로 해석
- 확률은 참고 지표, 확정 예측 아님
- 모델에 없는 정보는 스키마에서 제외

## 시각화





### 흑 카피

"삼성한테 2승 7패. 그런데 AI는 NC를 골랐다."

→ 상대전적과 모델 예측이 어긋나는 지점을 흑으로 사용

### 팀 로고 · 컬러

10개 구단 로고(SVG) + 팀 대표색 자동 반영

### 상대전적

head\_to\_head.py가 별도 집계 (모델 입력 변수 아님, 표시용)

### 승부처 + 확률 바

SHAP 상위 요인 하나 + 홈/원정 승률을 시각적 바로 표현

## 활용 방안

파이프라인(모델 → 예측 → LLM 코멘터리 → SNS 카드)을 그대로 반복 실행해 매경기 자동 운영 가능

### 경기 전 SNS 콘텐츠

라인업 확정되면 스토리 카드 생성  
별도 디자인 작업 불필요

### 본방송 연계

승률·상대전적·승부처 지표를 그래픽으로  
코멘터리를 MC 브리핑 자료로 활용

## 한계 및 유의사항

### 검증 표본 한정

107경기 기준, 데이터 누적 전까지는 참고 지표

### 지표 안정성

973경기도 여전히 소표본 → 데이터 누적 시 주  
요 지표 변동 가능

### 낮은 신뢰도 경기 존재

자동으로 "팽팽한 접전" 등 확신 낮춘 표현 처리

### 비용

LLM API 키·비용 별도 필요

**감사합니다**